



Sentiment Analysis: Fallstricke eines scheinbar einfachen Tools




#NTF22 Workshop

Prof. Dr. Dennis Klinkhammer

Agenda

- Grundlegende Funktionsweise
- arXiv: Do-It-Yourself-Tutorials
- Fallstricke der Sentiment Analysis
- Referenzen



Grundlegende Funktionsweise

Grundlegende Funktionsweise

- Sentiment Analysis ist ein Untergebiet des Text Mining
- Methodische Grundlagen:
 - Statistik
 - Machine Learning
 - Natural Language Processing -> Deep Learning

Grundlegende Funktionsweise

- Algorithmenbasierte Verarbeitung von Text- und Sprachdaten
- Übergeordnetes Ziel der Sentiment Analysis

**Einschätzung der Haltung
(in Text- und Sprachdaten)
als positiv oder negativ**

Grundlegende Funktionsweise

- Wörtern wird nicht einfach ein Sentiment zugewiesen
- Wörter werden in Vektoren überführt, um deren Bedeutung in einem Satz abbilden zu können
- Gängige Tools, bspw. für Python
 - **Word2Vec** : Word to Vectors
 - **GloVe** : Global Vectors for Word Representation

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism
 - Fascism

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3)

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
[0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
[0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
[0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
[0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
 - Position + Häufigkeit (n) [0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
 - Position + Häufigkeit (n) [0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
 - Position + Häufigkeit (n) [0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise

- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1]
 - Position + Häufigkeit (n) [0, 0, 1, 0, 2, 1]
[0, 0, 0, 1, 3, 1]

Grundlegende Funktionsweise


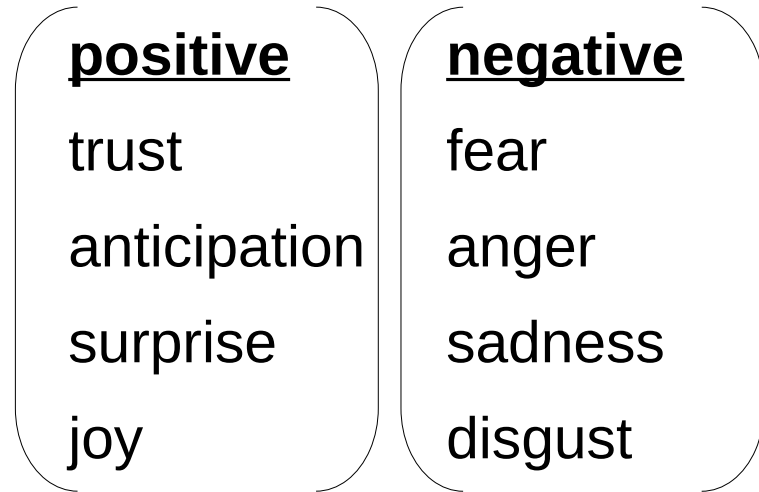
- One Hot Encoding und Word Embedding ermöglichen Vektorisierung
- Beispiel für One Hot Encoding:
 - Marxism = [1, 0, 0, 0]
 - Fascism = [0, 1, 0, 0]
- Beispiel für Word Embedding:
 - Marxism (1) is (2) good (3) -> [1, 0, 0, 0, 1, 1] + [?]
 - Position + Häufigkeit (n) [0, 0, 1, 0, 2, 1] + [?]
[0, 0, 0, 1, 3, 1] + [?]

Sentiment




Grundlegende Funktionsweise

- **NRC** Word-Emotion Association Lexicon
- 2 Sentiments und 8 Emotions



Grundlegende Funktionsweise

- NRC Word-Emotion Association Lexicon **Affect Categories**



Grundlegende Funktionsweise

- NRC Word-Emotion Association Lexicon **Set of Categories**

negative	fear		anger fear negative	anger	trust positive		joy trust		sadness negative	fear sadness negative
			anger fear sadness		trust				anger disgust fear sadness negative	anger fear sadness negative
	fear		anger disgust fear sadness negative							
sadness negative			anger disgust negative		fear negative	fear	anger fear negative	anger disgust fear	anger disgust fear sadness negative	anger
					fear		anger fear sadness negative		disgust negative	joy positive
positive		trust positive		joy positive						joy trust positive
				joy trust positive	anger fear negative	anger fear sadness	anger disgust fear sadness negative	anger		anticip joy trust positive
					anger negative				anticip	anticip joy trust positive



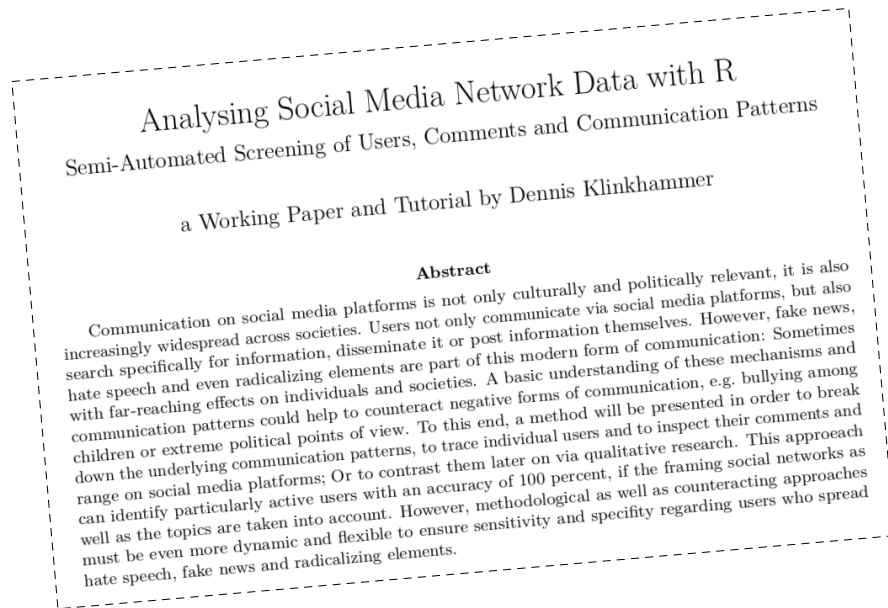
arXiv: Do-It-Yourself-Tutorials

arXiv: Do-It-Yourself-Tutorials

- Aktuelle Entwicklungen der Sentiment Analysis lassen sich zum gegenwärtigen Zeitpunkt am besten auf arXiv nachvollziehen

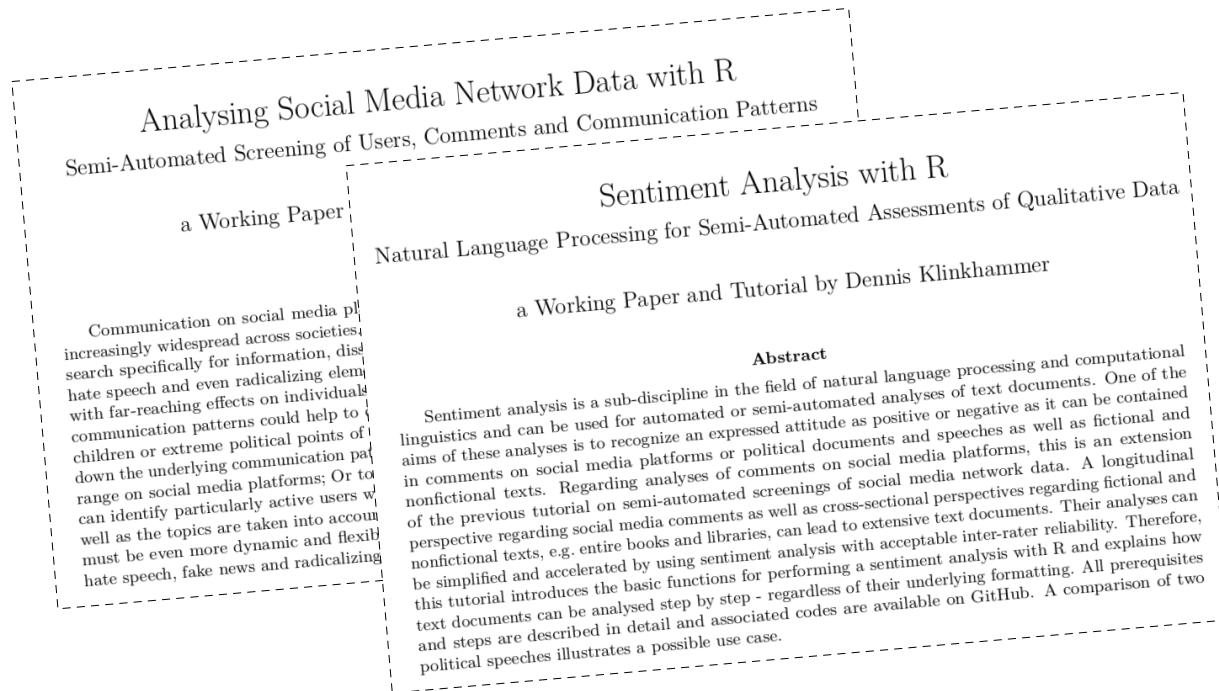
arXiv: Do-It-Yourself-Tutorials

- Aktuelle Entwicklungen der Sentiment Analysis lassen sich zum gegenwärtigen Zeitpunkt am besten auf arXiv nachvollziehen



arXiv: Do-It-Yourself-Tutorials

- Aktuelle Entwicklungen der Sentiment Analysis lassen sich zum gegenwärtigen Zeitpunkt am besten auf arXiv nachvollziehen



arXiv: Do-It-Yourself-Tutorials

- Aktuelle Entwicklungen der Sentiment Analysis lassen sich zum gegenwärtigen Zeitpunkt am besten auf arXiv nachvollziehen

Analysing Social Media Network Data with R
Semi-Automated Screening of Users, Comments and Communication Patterns
a Working Paper

Communication on social media platforms is increasingly widespread across societies, search specifically for information, disseminate hate speech and even radicalizing elements. With far-reaching effects on individual communication patterns could help to bring down the underlying communication patterns on social media platforms; Or to identify particularly active users as well as the topics are taken into account must be even more dynamic and flexible. Hate speech, fake news and radicalizing

Sentiment Analysis with R
Natural Language Processing for Semi-Automated Assessment
a Working Paper and Tutorial by Dennis Klink

Abstract

Sentiment analysis is a sub-discipline in the field of natural language processing and linguistics and can be used for automated or semi-automated analyses of texts. One of the aims of these analyses is to recognize an expressed attitude as positive or negative in comments on social media platforms or political documents and news articles in nonfictional texts. Regarding analyses of comments on social media platforms of the previous tutorial on semi-automated screenings of social media platforms, a perspective regarding social media comments as well as cross-sectional perspectives on nonfictional texts, e.g. entire books and libraries, can lead to extensive text analysis. This tutorial introduces the basic functions for performing a sentiment analysis and be simplified and accelerated by using sentiment analysis with acceptable accuracy. This tutorial introduces the basic functions for performing a sentiment analysis and text documents can be analysed step by step - regardless of their underlying structure and steps are described in detail and associated codes are available on GitHub. Political speeches illustrates a possible use case.

Sentiment Analysis: Automatically Detecting Valence, Emotions, and Other Affectual States from Text

Saif M. Mohammad
National Research Council Canada
1200 Montreal Rd., Ottawa, ON, Canada

SAIF.MOHAMMAD@NRC-CNRC.GC.CA

Abstract

Recent advances in machine learning have led to computer systems that are human-like in behaviour. Sentiment analysis, the automatic determination of emotions in text, is allowing us to capitalize on substantial previously unattainable opportunities in commerce, public health, government policy, social sciences, and art. Further, analysis of emotions in text, from news to social media posts, is improving our understanding of not just how people convey emotions through language but also how emotions shape our behaviour. This article presents a sweeping overview of sentiment analysis research that includes: the origins of the field, the rich landscape of tasks, challenges, a survey of the methods and resources used, and applications. We also discuss how, without careful fore-thought, sentiment analysis has the potential for harmful outcomes. We outline the latest lines of research in pursuit of fairness in sentiment analysis.

Keywords: *sentiment analysis, emotions, artificial intelligence, machine learning, natural language processing (NLP), social media, emotion lexicons, fairness in NLP*

arXiv: Do-It-Yourself-Tutorials

- In diesem Beispiel wird ein Text für die Sentiment Analysis vorbereitet

```
text_df <- tibble(line=1:229, text=imported_text$V1)
head(text_df)
```

```
## # A tibble: 6 x 2
##   line text
##   <int> <chr>
## 1     1 "To Sherlock Holmes she is always the woman. I have seldom heard him"
## 2     2 "      mention her under any other name. In his eyes she eclipses and"
## 3     3 "      predominates the whole of her sex. It was not that he felt any"
## 4     4 "      emotion akin to love for Irene Adler. All emotions, and that one"
## 5     5 "      particularly, were abhorrent to his cold, precise but admirably"
## 6     6 "      balanced mind. He was, I take it, the most perfect reasoning and"
```

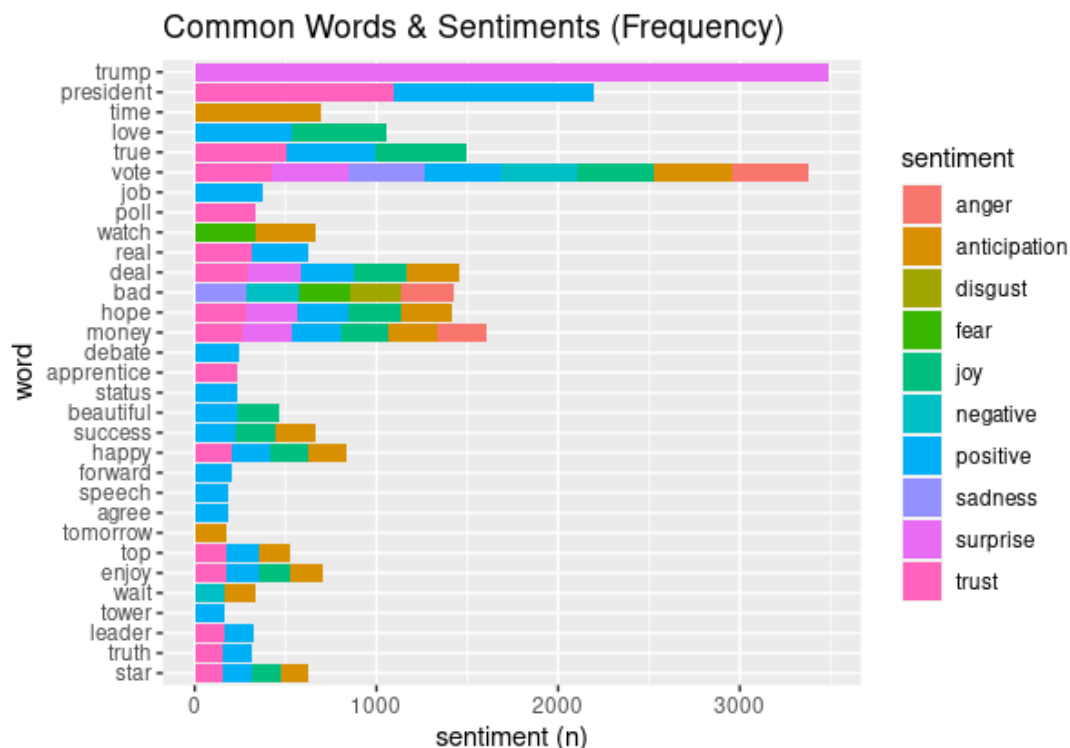
arXiv: Do-It-Yourself-Tutorials

- Darüber hinaus steht eine bedarfsspezifische Ergebnisdarstellung im Vordergrund der Do-It-Yourself-Tutorials

```
nrc_word_counts %>%  
  filter(n > 2) %>%  
  mutate(word = reorder(word, n)) %>%  
  ggplot(aes(word, n, fill = sentiment)) +  
  geom_col() +  
  coord_flip() +  
  labs(y = "sentiment (n)") +  
  ggtitle("Common Words & Sentiments (Frequency)")
```

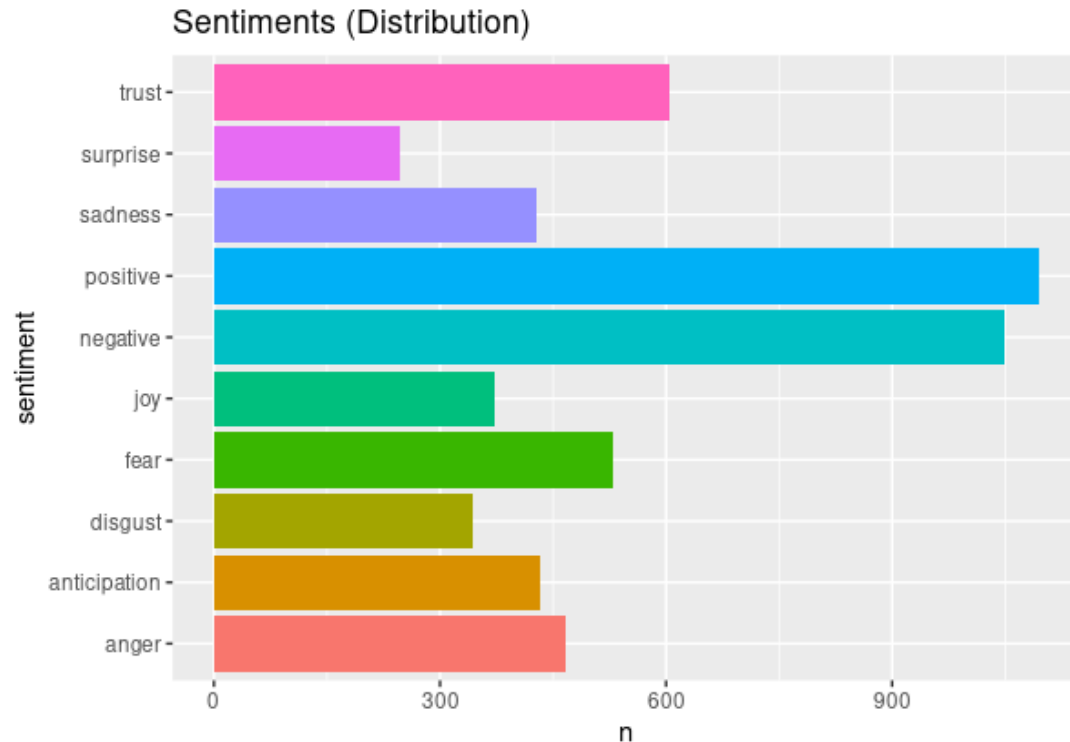

arXiv: Do-It-Yourself-Tutorials

- Beispiel: Sentiment Analysis der **Tweets** von Donald Trump - I




arXiv: Do-It-Yourself-Tutorials

- Beispiel: Sentiment Analysis der **Tweets** von Donald Trump - II




arXiv: Do-It-Yourself-Tutorials

- Beispiel: Sentiment Analysis der **Tweets** von Donald Trump - III



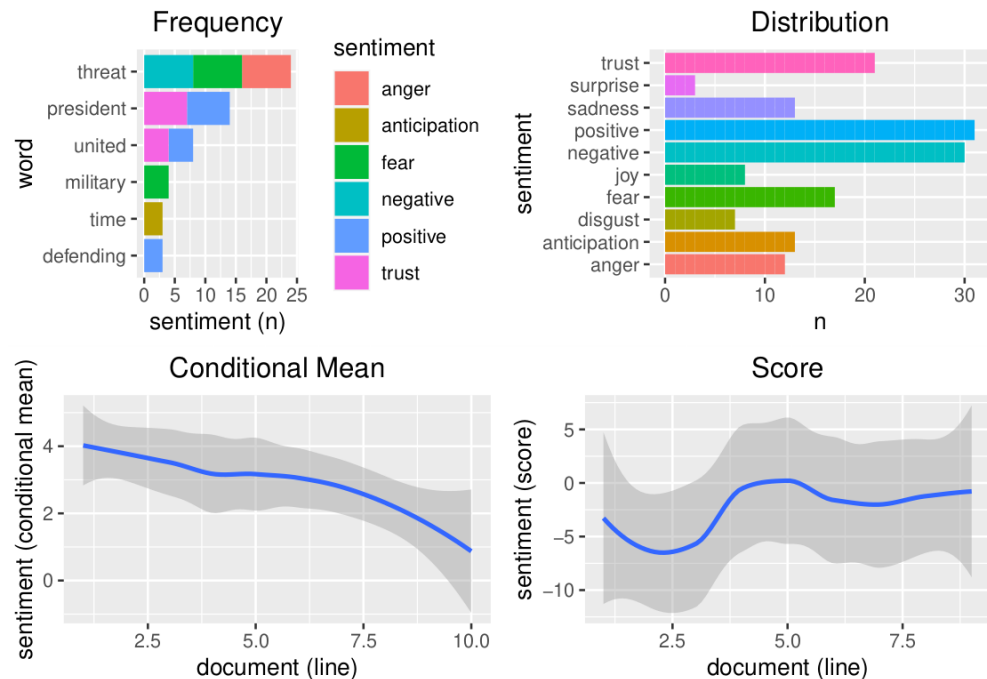
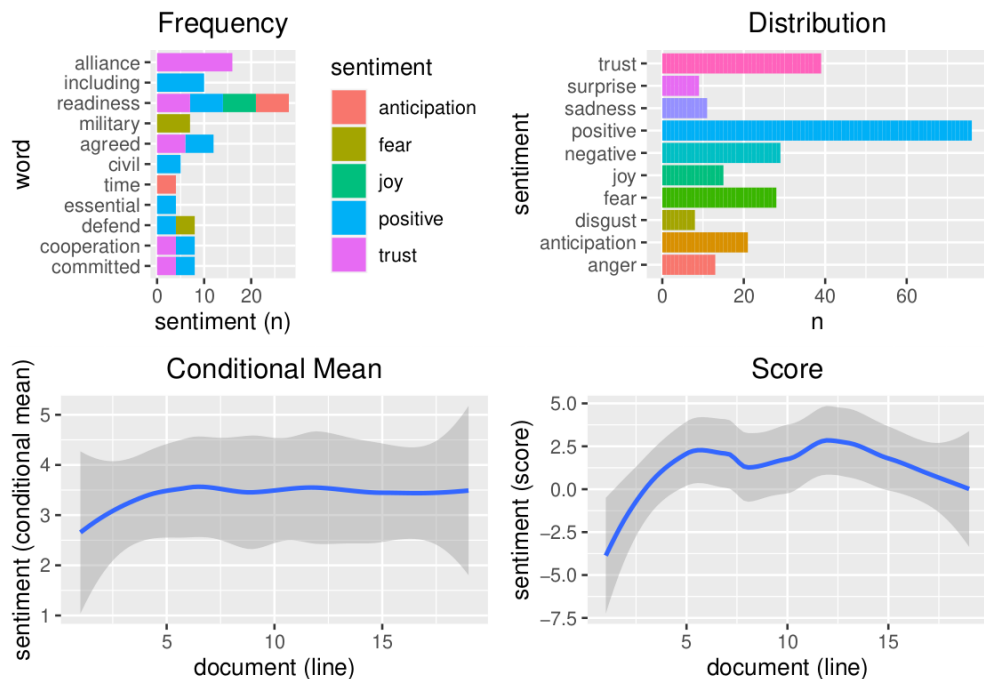
arXiv: Do-It-Yourself-Tutorials

- Beispiel: Sentiment Analysis der **Tweets** von Donald Trump - IV



arXiv: Do-It-Yourself-Tutorials

- Ein sprachlicher Vergleich zwischen **Stoltenberg** (l.) und **Lawrow** (r.)





Fallstricke der Sentiment Analysis

Fallstricke der Sentiment Analysis

- Übernahme von bestehenden Tools, ohne Verständnis der zugrundeliegenden **Programmiersprache**

Fallstricke der Sentiment Analysis

- Übernahme von bestehenden Tools, ohne Verständnis der zugrundeliegenden **Programmiersprache**
- Keine bzw. unzureichende Kenntnis der Funktionsweise von Natural Language Processing (**Deep Learning**, insb. Aktivierungsfunktionen)

Fallstricke der Sentiment Analysis

- Übernahme von bestehenden Tools, ohne Verständnis der zugrundeliegenden **Programmiersprache**
- Keine bzw. unzureichende Kenntnis der Funktionsweise von Natural Language Processing (**Deep Learning**, insb. Aktivierungsfunktionen)
- Keine bzw. unzureichende Berücksichtigung des geographischen und (!) zeitlichen **Kontextes**


Fallstricke der Sentiment Analysis

- Übernahme von bestehenden Tools, ohne Verständnis der zugrundeliegenden **Programmiersprache**
- Keine bzw. unzureichende Kenntnis der Funktionsweise von Natural Language Processing (**Deep Learning**, insb. Aktivierungsfunktionen)
- Keine bzw. unzureichende Berücksichtigung des geographischen und (!) zeitlichen **Kontextes**
- Rückgriff auf nicht aktualisierte bzw. unspezifische **Lexika**

Fallstricke der Sentiment Analysis


- Übernahme von bestehenden Tools, ohne Verständnis der zugrundeliegenden **Programmiersprache**
- Keine bzw. unzureichende Kenntnis der Funktionsweise von Natural Language Processing (**Deep Learning**, insb. Aktivierungsfunktionen)
- Keine bzw. unzureichende Berücksichtigung des geographischen und (!) zeitlichen **Kontextes**
- Rückgriff auf nicht aktualisierte bzw. unspezifische **Lexika**
- **Transfer Learning** nur eingeschränkt möglich (!)

Vielen Dank für die Aufmerksamkeit



Statistical Thinking

Mehr Beispiele
zur Statistik mit
Python und R



Referenzen

- (1) Grogan, M. (2020): *NLP from a time series perspective. How time series analysis can complement NLP*. Towards Data Science.
- (2) Hamachers, A., Weber, K., Widmann, J. & S. Jarolimek (2020): *Extremistische Dynamiken im Social Web*. Frankfurt am Main: Verlag für Polizeiwissenschaft.
- (3) Iacus, S. M. & G. Porro (2022): *Using social networks to measure subjective well-being*. In: Significance. Volume 19. Issue 3.
- (4) Klinkhammer, D. (2020): *Analysing Social Media Network Data with R: Semi-Automated Screening of Users, Comments and Communication Patterns*. Cornell University (arXiv).
- (5) Klinkhammer, D. (2022): *Sentiment Analysis with R: Natural Language Processing for Semi Automated Assessments of Qualitative Data*. Cornell University (arXiv).
- (6) Ng, A. (2022): Deep Learning Specialization. DeepLearning.AI, Palo Alto, CA (USA).
- (7) Mohammad, S. M. (2021): *Sentiment Analysis: Automatically Detecting Valence, Emotions and Other Affectual States from Text*. Cornell University (arXiv).